

LAPORAN PROYEK

Klasifikasi & Clustering

Evaluasi Model Machine Learning pada Data Kanker Payudara

Dataset

Breast Cancer Wisconsin (Diagnostic)

Algoritma Klasifikasi

SVM, Decision Tree, Naive Bayes

Algoritma Clustering

K-Means, DBSCAN

Disusun oleh

Ariko Yahya Setyawan — Fisika

Ringkasan Proyek


Proyek ini membangun dan membandingkan model **klasifikasi** serta **clustering** menggunakan dataset *Breast Cancer Wisconsin (Diagnostic)* dari Kaggle/scikit-learn, berisi 569 sampel hasil pengukuran citra digital massa payudara dengan 30 fitur numerik dan label diagnosis **Malignant (M)** — ganas, atau **Benign (B)** — jinak.

Alur kerja mencakup eksplorasi data, praproses (scaling & split), pelatihan tiga model klasifikasi supervised, penerapan dua algoritma clustering unsupervised, hingga evaluasi menyeluruh dan visualisasi hasil menggunakan reduksi dimensi PCA.

Tujuan Analisis

- Membandingkan performa SVM, Decision Tree, dan Naive Bayes dalam klasifikasi diagnosis.
- Mengelompokkan data secara unsupervised dengan K-Means & DBSCAN, dibandingkan dengan label asli.
- Mengevaluasi model dengan metrik standar (Accuracy, Precision, Recall, F1, Silhouette, Davies-Bouldin).

Distribusi Kelas Diagnosis





Benign (B) lebih banyak dibanding Malignant (M) pada dataset.

Tahapan Notebook

1	Import Library & Load Dataset	4	Klasifikasi — SVM, Decision Tree, Naive Bayes + Evaluasi
2	Eksplorasi Data (EDA) & Cek Missing Value	5	Clustering — Elbow Method, K-Means, DBSCAN + PCA
3	Preprocessing — Split Data & Standardisasi	6	Rangkuman Evaluasi & Ekspor Hasil ke CSV

Hasil Klasifikasi

Tiga algoritma klasifikasi — **SVM**, **Decision Tree**, dan **Naive Bayes** — dilatih pada data yang telah distandardisasi, lalu dievaluasi menggunakan metrik Accuracy, Precision, Recall, dan F1-Score.




Tabel Perbandingan Metrik Klasifikasi

Model	Accuracy	Precision	Recall	F1-Score
SVM	0.982	0.986	0.986	0.986
Decision Tree	0.939	0.958	0.944	0.951
Naive Bayes	0.930	0.944	0.944	0.944


SVM unggul di seluruh metrik dan menjadi model klasifikasi terbaik pada dataset ini.

Grafik Perbandingan Model




Perbandingan Accuracy, Precision, Recall, F1-Score ketiga model.

Korelasi Fitur terhadap Target



Heatmap korelasi 10 fitur pertama terhadap label diagnosis.


Confusion Matrix Ketiga Model



Confusion matrix SVM, Decision Tree, dan Naive Bayes pada data uji — SVM memiliki kesalahan klasifikasi paling sedikit.

Visualisasi Struktur Decision Tree

Visualisasi Decision Tree (2 level pertama)




Struktur pohon keputusan (disederhanakan hingga kedalaman 3) menunjukkan fitur pemisah utama antar kelas.

Hasil Clustering

Analisis clustering dilakukan secara *unsupervised* menggunakan **K-Means** dan **DBSCAN**. Jumlah kluster optimal untuk K-Means ditentukan melalui **Elbow Method**, dan hasil akhir divisualisasikan dalam ruang 2D menggunakan reduksi dimensi PCA.

Elbow Method — Jumlah Kluster Optimal




Titik 'siku' pada grafik menunjukkan $k=2$ sebagai jumlah kluster paling optimal.

Tabel Evaluasi Clustering

Model	Kluster	Silhouette	Davies-Bouldin
K-Means	2	0.343	1.321
DBSCAN	1*	—	—

* Dengan parameter default ($\text{eps}=3.0$, $\text{min_samples}=5$), DBSCAN menghasilkan satu kluster tunggal pada dataset ini.

Visualisasi Hasil Clustering (PCA 2D)



Proyeksi 2D hasil K-Means, DBSCAN, dan label asli — pola kluster K-Means paling mendekati label diagnosis sebenarnya.

Kesimpulan

1 Model Klasifikasi Terbaik: SVM

SVM mencapai performa tertinggi di seluruh metrik (Accuracy 98.2%, F1-Score 98.6%), menjadikannya model paling andal untuk membedakan diagnosis Malignant dan Benign pada dataset ini.

3 DBSCAN Kurang Optimal pada Parameter Default

Dengan $\text{eps}=3.0$ dan $\text{min_samples}=5$, DBSCAN hanya menghasilkan satu kluster tunggal, menandakan diperlukan tuning parameter lebih lanjut agar dapat memisahkan data secara lebih granular.

2 Model Clustering Terbaik: K-Means

K-Means dengan $k=2$ memberikan Silhouette Score 0.343 dan Davies-Bouldin Index 1.321, mengelompokkan data secara wajar menjadi dua kluster yang selaras dengan dua kelas diagnosis asli.

4 Pentingnya Standardisasi Fitur

Karena SVM dan K-Means sensitif terhadap skala data, penerapan StandardScaler sebelum pemodelan terbukti krusial untuk hasil optimal dan dapat direproduksi ($\text{random_state}=42$).

Ringkasan Akhir: Untuk tugas klasifikasi diagnosis kanker payudara, **SVM** adalah pilihan terbaik dengan performa hampir sempurna. Untuk eksplorasi pola data tanpa label, **K-Means (k=2)** berhasil menemukan struktur kluster yang paling merepresentasikan dua kelompok diagnosis alami dalam data.